


Fundamentos de Inteligencia Artificial

Para Deep Learning y Redes Neuronales



Conceptos Esenciales con Visualizaciones


Preparacion para el Proyecto HAR

Índice

1. Introduccion: ¿Que es el Aprendizaje Automatico?	2
2. El Perceptron: La Neurona Artificial	2
3. Funciones de Activacion	3
3.1. Funciones Comunes	3
4. Redes Neuronales Multicapa (MLP)	4
4.1. Forward Pass (Propagacion hacia adelante)	5
5. Funcion de Perdida (Loss Function)	5
5.1. Cross-Entropy para Clasificacion	5
6. Backpropagation y Gradiente Descendente	6
6.1. Intuicion del Gradiente	6
6.2. Regla de la Cadena	7
7. Optimizadores	7
7.1. SGD (Stochastic Gradient Descent)	7
7.2. Adam (Adaptive Moment Estimation)	8
8. Regularizacion: Evitando el Sobreajuste	8
8.1. Tecnicas de Regularizacion	8
9. Redes Neuronales Convolucionales (CNN)	9
9.1. Convolucion 1D (para senales)	9
9.2. Por que CNN para HAR?	10
9.3. Arquitectura CNN-1D + MLP	10
10. Entrenamiento en PyTorch	10
10.1. Estructura Tipica	10
10.2. Batches y Epocas	11
11. Metricas de Evaluacion	11
11.1. Accuracy	11
11.2. Matriz de Confusion	12
12. K-Fold Cross Validation	12
13. Resumen: Flujo Completo	13
14. Tabla Resumen de Conceptos	13

1. Introducción: ¿Qué es el Aprendizaje Automático?

El **aprendizaje automático** (Machine Learning) es un paradigma donde los algoritmos *aprenden patrones* a partir de datos, en lugar de ser programados explicitamente con reglas.



Tipos de Aprendizaje


- **Supervisado:** Tenemos datos etiquetados (X, y). El modelo aprende a predecir y dado X .
- **No supervisado:** Solo tenemos X . El modelo encuentra patrones (clustering, reducción de dimensionalidad).
- **Por refuerzo:** El modelo aprende mediante prueba y error, recibiendo recompensas.

En la Práctica:

Proyecto HAR Nuestro proyecto es **aprendizaje supervisado**: tenemos datos de sensores (X) y etiquetas de actividad ($y = \text{WALKING}, \text{SITTING}$, etc.). El modelo aprenderá a clasificar nuevas lecturas.

2. El Perceptrón: La Neurona Artificial

El **perceptrón** es la unidad básica de las redes neuronales, inspirado en la neurona biológica.




Componentes del Perceptrón


- **Entradas** (x_1, x_2, \dots, x_n): Valores de las características.
- **Pesos** (w_1, w_2, \dots, w_n): Importancia de cada entrada (parámetros aprendibles).
- **Bias** (b): Término independiente que desplaza la frontera de decisión.
- **Suma ponderada:** $z = \sum_{i=1}^n w_i x_i + b = \mathbf{w}^T \mathbf{x} + b$
- **Función de activación** (σ): Introduce no-linealidad.

3. Funciones de Activación

Las funciones de activación son **cruciales** porque introducen **no-linealidad**, permitiendo a la red aprender patrones complejos.

3.1. Funciones Comunes





$$\text{softmax}(z_i) = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}}$$

Suma de todas = 1

Importante


- **ReLU**: Usada en capas ocultas (rapida, evita vanishing gradient).
- **Sigmoid**: Salida binaria (0 a 1), usada en clasificacion binaria.
- **Softmax**: Salida multiclas (probabilidades que suman 1).

En la Practica:

HAR - 6 Clases Para clasificar 6 actividades, usaremos **Softmax** en la capa de salida. La red producira 6 probabilidades (una por clase) que suman 1.

4. Redes Neuronales Multicapa (MLP)

Un **Perceptron Multicapa** (MLP) apila multiples capas de neuronas para aprender representaciones cada vez mas abstractas.



4.1. Forward Pass (Propagacion hacia adelante)

Forward Pass

El calculo de la salida dado una entrada \mathbf{x} :

$$\begin{aligned}\mathbf{z}^{(1)} &= \mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(1)} && \text{(combinacion lineal)} \\ \mathbf{a}^{(1)} &= \sigma(\mathbf{z}^{(1)}) && \text{(activacion, ej. ReLU)} \\ \mathbf{z}^{(2)} &= \mathbf{W}^{(2)}\mathbf{a}^{(1)} + \mathbf{b}^{(2)} \\ \mathbf{a}^{(2)} &= \sigma(\mathbf{z}^{(2)}) \\ \mathbf{z}^{(3)} &= \mathbf{W}^{(3)}\mathbf{a}^{(2)} + \mathbf{b}^{(3)} \\ \hat{\mathbf{y}} &= \text{softmax}(\mathbf{z}^{(3)}) && \text{(probabilidades de clase)}\end{aligned}$$

Intuicion:

Por que capas ocultas? Cada capa aprende **representaciones** mas abstractas:

- **Capa 1:** Detecta patrones simples (bordes, picos en senales).
- **Capa 2:** Combina patrones simples (formas, secuencias).
- **Capa 3:** Reconoce conceptos de alto nivel (objetos, actividades).

5. Funcion de Perdida (Loss Function)

La **funcion de perdida** mide que tan lejos estan las predicciones del modelo de los valores reales. El objetivo del entrenamiento es **minimizar** esta funcion.

5.1. Cross-Entropy para Clasificacion

Cross-Entropy Loss

Para clasificacion multiclas con K clases:

$$\mathcal{L} = - \sum_{i=1}^K y_i \log(\hat{y}_i)$$

Donde:

- y_i : Etiqueta real (one-hot: 1 si es la clase correcta, 0 si no).
- \hat{y}_i : Probabilidad predicha para la clase i .

Ejemplo:


Cross-Entropy Supongamos que la clase real es “WALKING” (clase 1 de 3):

- Etiqueta one-hot: $\mathbf{y} = [1, 0, 0]$

- Prediccion del modelo: $\hat{y} = [0,7, 0,2, 0,1]$
- Loss: $\mathcal{L} = -[1 \cdot \log(0,7) + 0 \cdot \log(0,2) + 0 \cdot \log(0,1)]$
- $\mathcal{L} = -\log(0,7) \approx 0,357$

Si la prediccion fuera perfecta ($\hat{y} = [1, 0, 0]$):


- $\mathcal{L} = -\log(1) = 0$ (perdida minima)



6. Backpropagation y Gradiente Descendente

Backpropagation es el algoritmo que calcula como ajustar los pesos para reducir la perdida. Usa la **regla de la cadena** del calculo.

6.1. Intuicion del Gradiente



Regla de Actualización


$$w_{\text{nuevo}} = w_{\text{actual}} - \eta \frac{\partial \mathcal{L}}{\partial w}$$

Donde:

- η : Tasa de aprendizaje (learning rate).
- $\frac{\partial \mathcal{L}}{\partial w}$: Gradiente (dirección de mayor aumento de la perdida).

6.2. Regla de la Cadena

Para calcular $\frac{\partial \mathcal{L}}{\partial w}$ en capas profundas, aplicamos la **regla de la cadena**:



$$\frac{\partial \mathcal{L}}{\partial w} = \frac{\partial \mathcal{L}}{\partial a} \cdot \frac{\partial a}{\partial z} \cdot \frac{\partial z}{\partial w}$$

Importante

La **backpropagation** propaga los gradientes *hacia atras* desde la salida hasta la entrada, calculando cuánto contribuye cada peso a la perdida total.

7. Optimizadores

Los **optimizadores** son algoritmos que mejoran el gradiente descendente básico.

7.1. SGD (Stochastic Gradient Descent)

SGD con Momentum

$$\begin{aligned} v_t &= \beta v_{t-1} + \eta \nabla \mathcal{L}(w_t) \\ w_{t+1} &= w_t - v_t \end{aligned}$$

El **momentum** ($\beta \approx 0,9$) acumula velocidad, ayudando a superar mínimos locales.

7.2. Adam (Adaptive Moment Estimation)

Adam

Combina momentum con tasas de aprendizaje adaptativas:

$$\begin{aligned} m_t &= \beta_1 m_{t-1} + (1 - \beta_1) \nabla \mathcal{L} && \text{(primer momento)} \\ v_t &= \beta_2 v_{t-1} + (1 - \beta_2) (\nabla \mathcal{L})^2 && \text{(segundo momento)} \\ w_{t+1} &= w_t - \eta \frac{m_t}{\sqrt{v_t} + \epsilon} \end{aligned}$$


Valores tipicos: $\beta_1 = 0,9$, $\beta_2 = 0,999$, $\epsilon = 10^{-8}$.

En la Practica:

Cual usar? **Adam** es el optimizador mas popular por su robustez. Es una excelente opcion por defecto para la mayoria de problemas, incluyendo HAR.

8. Regularizacion: Evitando el Sobreajuste

El **sobreajuste** (overfitting) ocurre cuando el modelo memoriza los datos de entrenamiento pero no generaliza a datos nuevos.



8.1. Tecnicas de Regularizacion


Dropout

Durante el entrenamiento, “apaga” aleatoriamente un porcentaje de neuronas en cada iteracion:

$$h_i = \begin{cases} 0 & \text{con probabilidad } p \\ \frac{a_i}{1-p} & \text{con probabilidad } 1-p \end{cases}$$


Esto fuerza a la red a no depender de neuronas especificas.

Sin Dropout

Con Dropout ($p=0.5$)

Early Stopping

Detener el entrenamiento cuando la **perdida de validacion** deja de mejorar:



9. Redes Neuronales Convolucionales (CNN)

Las **CNN** son arquitecturas especializadas para datos con estructura espacial o temporal (imagenes, senales).


9.1. Convolucion 1D (para senales)

Convolucion 1D

Un **filtro** (kernel) se desliza sobre la senal, calculando productos punto:

$$(x * w)[i] = \sum_{k=0}^{K-1} x[i+k] \cdot w[k]$$

Donde K es el tamano del kernel.




9.2. Por que CNN para HAR?

En la Practica:

Senales de Sensores Los datos HAR son **series temporales** de 128 timesteps. La convolucion 1D:

- Detecta **patrones locales** en el tiempo (picos, valles, ritmos).
- Es **invariante a la posicion**: reconoce el mismo patron sin importar cuando ocurra.
- Reduce parametros vs MLP al compartir pesos en el kernel.

9.3. Arquitectura CNN-1D + MLP



10. Entrenamiento en PyTorch

10.1. Estructura Tipica

Ciclo de Entrenamiento

1. **Forward pass:** Calcular predicciones $\hat{y} = \text{model}(x)$
2. **Calcular loss:** $\mathcal{L} = \text{criterion}(\hat{y}, y)$
3. **Backward pass:** `loss.backward()` (calcula gradientes)
4. **Actualizar pesos:** `optimizer.step()`
5. **Limpiar gradientes:** `optimizer.zero_grad()`

Ejemplo:

Codigo PyTorch

```
for epoch in range(num_epochs):
    for X_batch, y_batch in dataloader:
        # Forward
        outputs = model(X_batch)
        loss = criterion(outputs, y_batch)

        # Backward
        optimizer.zero_grad()
        loss.backward()
        optimizer.step()
```

10.2. Batches y Epocas

Terminologia

- **Batch:** Subconjunto de datos procesados juntos (ej. 32 muestras).
- **Epoca:** Una pasada completa por todo el dataset.
- **Iteracion:** Procesamiento de un batch.

Si tenemos 7352 muestras y batch_size=32:

$$\text{Iteraciones por epoca} = \lceil 7352/32 \rceil = 230$$

11. Metricas de Evaluacion

11.1. Accuracy

Accuracy

$$\text{Accuracy} = \frac{\text{Predicciones correctas}}{\text{Total de muestras}} = \frac{TP + TN}{TP + TN + FP + FN}$$

11.2. Matriz de Confusión

		Predicho					
		WALK	UP	DOWN	SIT	STAND	LAY
Real	WALK	3	2	0	0	0	0
	UP	5	5	1	1	0	0
	DOWN	3	4	2	1	0	0
	SIT	0	1	12	1	1	0
	STAND	0	0	10	1	1	0
	LAY	0	0	1	1	1	0

Importante

La diagonal muestra las predicciones correctas. Los valores fuera de la diagonal son errores. Nota como SIT y STAND se confunden entre si (actividades similares).

12. K-Fold Cross Validation

K-Fold

Divide los datos en K partes (folds). Entrena K veces, cada vez usando un fold diferente como validacion:

5-Fold Cross Validation


Fold 1:	Val	Train	Train	Train	Train
Fold 2:	Train	Val	Train	Train	Train
Fold 3:	Train	Train	Val	Train	Train
Fold 4:	Train	Train	Train	Val	Train
Fold 5:	Train	Train	Train	Train	Val

Resultado final:

$$\text{Accuracy} = \frac{1}{K} \sum_{i=1}^K \text{Acc}_i$$

Mas robusto que una sola division train/val

13. Resumen: Flujo Completo



14. Tabla Resumen de Conceptos

primary!20 Concepto	Descripcion	En PyTorch / HAR
Perceptron	Neurona basica: $z = \mathbf{w}^T \mathbf{x} + b$	<code>nn.Linear(in, out)</code>
ReLU	Activacion: $\max(0, z)$	<code>nn.ReLU()</code>
Softmax	Probabilidades multiclase	<code>nn.Softmax(dim=1)</code> (implicito en CrossEntropyLoss)
Cross-Entropy	Loss para clasificacion	<code>nn.CrossEntropyLoss()</code>
Backpropagation	Calculo de gradientes	<code>loss.backward()</code>
Adam	Optimizador adaptativo	<code>optim.Adam(params, lr=0.001)</code>
Conv1D	Convolucion para secuencias	<code>nn.Conv1d(in_ch, out_ch, kernel)</code>
Dropout	Regularizacion	<code>nn.Dropout(p=0.5)</code>
Batch	Subconjunto de datos	<code>DataLoader(batch_size=32)</code>
Early Stopping	Detener si val_loss no mejora	Implementar manualmente

En la Practica:

Siguiente Paso Con estos fundamentos, estas listo para implementar tu modelo CNN-1D + MLP para clasificar las 6 actividades del dataset HAR. El notebook `resolucion.ipynb` te espera.